



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Instituto de Investigaciones en Matemáticas Aplicadas y
Sistemas

Proyecto Final: Calidad y Preprocesamiento de Datos

PRESENTA

Díaz Juárez Ana Sofía
Esteva Gallegos Carlos Fabián
León Navarrete Adam Edmundo
Munive Ramírez Ibrahim
Tapia Martínez Fernando

PROFESOR

Víctor Manuel Corza Vargas

ASIGNATURA

Calidad y Preprocesamiento de Datos

1. Descripción del área de negocio elegida

El proyecto se enfoca en la intersección de las áreas de **Salud Pública y Energía Nuclear**. Específicamente, se monitorea la radiación ambiental en los Estados Unidos y su relación con la ubicación e infraestructura de las plantas de energía nuclear. El objetivo es determinar si las características físicas o la proximidad de estas plantas influyen en los niveles de radiación detectados, lo que tiene un impacto fundamental en las decisiones de salud pública, política energética y seguridad ambiental.

2. Descripción de las fuentes de datos elegidas

Para abordar la problemática planteada, se han seleccionado dos fuentes principales de datos:

- **EPA RadNet (Radiación Ambiental):** Base de datos de la Agencia de Protección Ambiental (EPA), la cual rastrea la radiación ambiental (niveles gamma, dosis de radiación) a través de distintas estaciones de monitoreo. Es extraída vía una API REST y archivos ZIP históricos, contando con aproximadamente 17 millones de registros.
- **Nuclear Power Plants (Kaggle):** Conjunto de datos que contiene las ubicaciones, tipos de reactores, estado operativo y capacidad de las plantas de energía nuclear a nivel global, con un enfoque para este proyecto en las ubicadas en el territorio estadounidense.

3. Problemática y entendimiento del negocio

A partir de la exploración inicial de ambas fuentes, se identificaron 5 problemáticas de negocio que pueden llevar a una mala toma de decisiones regulatorias derivadas de una baja calidad de los datos:

1. **Registros de radiación sin fecha/hora (*timestamps* nulos o inválidos):** La ausencia de información temporal impide realizar análisis de series de tiempo fiables, lo que podría ocultar anomalías críticas en momentos específicos de la operación de una planta.
2. **Lecturas de radiación gamma nulas o fuera del rango físico:** La existencia de un 69,9 % de nulos o valores negativos de conteo de radiación provocan una evaluación sesgada del riesgo base, sugiriendo zonas "seguras" únicamente por la falta de recolección de datos.
3. **Plantas nucleares sin coordenadas geográficas:** La falta de latitud y longitud en los registros de ciertos reactores imposibilita el análisis espacial de proximidad, subestimando la exposición de ciertas estaciones poblacionales.

4. **Falta de estandarización en tipos de reactores:** Categorías nombradas de diferentes maneras (ej. *PWR*, *pressurized water reactor*, *vver*) impiden agrupar el impacto ambiental por tecnología, fragmentando el análisis regulatorio y complicando las comparativas.
5. **Outliers instrumentales por fallos de sensor:** Lecturas extremas pero físicamente imposibles (por ejemplo, dosis mayores a 100,000 nSv/h sin accidentes reportados) pueden activar falsas alarmas regulatorias, resultando en un desgaste innecesario y desperdicio de recursos de respuesta.

4. Propuesta de solución

Se ha propuesto un pipeline automatizado (orquestrado por `pipeline.py`) utilizando un framework de calidad (TDQM) implementado en Python. La solución se compone de:

- **Limpieza (Descriptiva/Prescriptiva):** Eliminación estricta de variables que rompan leyes físicas (ej. radiación negativa), purga de nulos críticos y estandarización de atributos de texto usando diccionarios globales como los de la IAEA.
- **Imputación de faltantes:** Cálculo prescriptivo de la mediana de los valores gamma por estación (`station_id`) para reemplazar valores nulos, conservando la distribución base local de cada sensor.
- **Enriquecimiento de datos:** Implementación de *geocoding* dinámico a través de la librería Nominatim (OpenStreetMap) para deducir e imputar las coordenadas geográficas de las plantas faltantes.

5. Reporte del perfilado de datos

El perfilado de los datos se llevó a cabo en el archivo `perfilado.py` valiéndose de la herramienta `ydata-profiling`. Se generó un reporte exhaustivo en formato HTML para `radiation-db.csv` (donde se realizó un muestreo de 50,000 filas para eficientizar los 1.7 GB de información total) y para `nuclear_power_plants.csv` (procesado al 100 % de sus 800 registros). Este perfilado permitió visibilizar la extrema cardinalidad en la tipología de reactores, detectar el altísimo índice de nulos en la columna de dosis (`dose_nSv_h`) y validar la dispersión estadística esperada de los contadores gamma.

5.1. Explicación del proceso de perfilado

Para realizar el perfilado de los datos se implementó el script `perfilado.py` utilizando la librería `ydata-profiling`, la cual permite generar reportes automáticos de calidad y estadísticas descriptivas del dataset.

```
1 df = pd.read_csv("radiation_db.csv")
2
3 profile = ProfileReport(
4     df.sample(50000),
5     title="Radiation Report"
6 )
7
8 profile.to_file("radiation_report.html")
```

Listing 1: Carga del dataset y generación del perfilado.

La función `pd.read_csv()` se utilizó para cargar el dataset de radiación dentro de un `DataFrame` de `pandas`.

Posteriormente, la función `sample(50000)` permitió tomar una muestra aleatoria de 50,000 registros con el objetivo de reducir el costo computacional asociado al procesamiento de más de 17 millones de registros originales.

La clase `ProfileReport()` genera automáticamente métricas estadísticas, distribución de variables, cardinalidad, correlaciones y análisis de valores faltantes dentro del conjunto de datos.

Finalmente, la función `to_file()` exportó el reporte completo en formato HTML para facilitar la inspección visual y el análisis exploratorio de los datos.

Gracias a este proceso fue posible identificar altos porcentajes de valores nulos en las columnas de radiación gamma, así como inconsistencias semánticas en la nomenclatura de los tipos de reactores nucleares.

6. Reporte del proceso de limpieza de datos

Ejecutado a través del script `limpieza.py`, el proceso de corrección de datos estableció las siguientes políticas:

- **Filtrado de rango físico:** Las tasas de dosis mayores a 100,000 nSv/h o menores a 0 nSv/h fueron reemplazadas por NaN para suprimir errores de instrumental. Lo mismo aplicó a conteos negativos de `gamma_cpm`.

- **Imputación y rastreo de linaje:** Los valores nulos de las distintas bandas gamma se imputaron usando la mediana histórica por estación. Además, se creó la columna `gamma_imputed` (un flag booleano) para marcar en qué registros hubo intervención.
- **Gestión de Outliers:** En lugar de eliminar ciegamente los valores atípicos, se identificaron usando el umbral del Rango Inter cuartílico ($IQR = 1,5$) por estación y se catalogaron con el atributo booleano `is_outlier`.
- **Estandarización Semántica:** Mapeo de diccionarios que convirtió decenas de sub-variaciones de texto de reactores hacia 8 categorías canónicas globales definidas por la IAEA (PWR, BWR, PHWR, RBMK, GCR, LWGR, FBR).

6.1. Explicación del proceso de limpieza de datos

El proceso de limpieza de datos fue implementado en el script `limpieza.py`, donde se aplicaron validaciones físicas, imputación de valores faltantes y detección de valores atípicos.

```
1 df.loc[df["dose_nSv_h"] < 0, "dose_nSv_h"] = np.nan
2
3 df.loc[df["dose_nSv_h"] > 100000,
4 "dose_nSv_h"] = np.nan
```

Listing 2: Filtrado de valores físicamente imposibles.

La función `loc[]` de pandas permitió seleccionar registros bajo una condición lógica específica. En este caso, todos los valores negativos o extremadamente altos de radiación fueron reemplazados por NaN, debido a que representan errores instrumentales o mediciones físicamente imposibles.

Posteriormente, los valores faltantes fueron imputados utilizando la mediana histórica por estación de monitoreo:

```
1 df["gamma_cpm"] = df.groupby("station_id")
2 ["gamma_cpm"].transform(
3 lambda x: x.fillna(x.median())
4 )
```

Listing 3: Imputación de valores faltantes por estación.

La función `groupby()` agrupó los datos por estación, mientras que `transform()` permitió aplicar la imputación conservando la estructura original del DataFrame.

Adicionalmente, `fillna()` sustituyó los valores nulos utilizando la mediana histórica de cada sensor, debido a que esta métrica es robusta frente a valores atípicos.

Finalmente, se implementó una bandera lógica para conservar el linaje de los datos modificados:

```
1 df["gamma_imputed"] =
2 df["gamma_cpm"].isna()
```

Listing 4: Creación de bandera de imputación.

La función `isna()` permitió identificar los registros originalmente faltantes antes de la imputación, facilitando auditorías posteriores sobre la calidad de los datos procesados.

7. Reporte sobre la obtención de datos maestros

La construcción del dato maestro consolidado se efectúa en `fusion.py`. Ambos datasets limpios se integran calculando de forma vectorizada la **Distancia de Haversine** entre todas las estaciones terrestres (RadNet) y todas las plantas nucleares de la base global. Posteriormente, se efectuó un filtrado de proximidad (Top-N) para extraer únicamente las 5 plantas más cercanas a cada estación individual, resultando en la tabla maestra consolidada `station_plant_distances.csv`.

7.1. Explicación del proceso de fusión de datos

La integración de las fuentes de datos fue realizada mediante el script `fusion.py`. Para relacionar las estaciones de monitoreo con las plantas nucleares se utilizó la Distancia de Haversine, la cual permite calcular distancias geográficas considerando la curvatura terrestre.

```
1 distance = haversine(  
2 (station_lat, station_lon),  
3 (plant_lat, plant_lon)  
4 )
```

Listing 5: Cálculo de distancia geográfica entre estaciones y plantas nucleares.

La función `haversine()` calcula la distancia entre dos coordenadas geográficas expresadas mediante latitud y longitud. Esto permitió determinar cuáles plantas nucleares se encuentran más cercanas a cada estación RadNet.

Posteriormente, se realizó un filtrado Top-N para conservar únicamente las cinco plantas más cercanas a cada estación:

```
1 df.sort_values("distance_km")  
2 .groupby("station_id")  
3 .head(5)
```

Listing 6: Selección de las plantas más cercanas.

La función `sort_values()` ordenó las distancias de menor a mayor, mientras que `groupby()` agrupó los registros por estación de monitoreo. Finalmente, `head(5)` conservó únicamente las cinco distancias mínimas de cada grupo.

8. Reporte sobre el preprocesamiento de datos realizado

El preprocesamiento final (ejecutado en la primera sección de `analisis.py`) se centró en aplicar funciones de agregación para manejar la volumetría original de 17 millones de filas. Se agruparon las lecturas a nivel estación calculando métricas compuestas como: el promedio `gamma_cpm_mean`,

desviaciones estándar, totales de anomalías observadas, porcentaje de imputaciones por sensor y un cruce con categorías discretas de distancia (ej. < 50 km, $50 - 200$ km, > 200 km).

8.1. Explicación del proceso de análisis y agregación

El análisis exploratorio y estadístico fue desarrollado mediante el script `analisis.py`, utilizando funciones de agregación y resumen estadístico para manejar el gran volumen de datos disponible.

```
1 summary = df.groupby("station_id").agg({  
2 "gamma_cpm": ["mean", "std"],  
3 "is_outlier": "sum"  
4 })
```

Listing 7: Agregación de métricas estadísticas por estación.

La función `groupby()` permitió agrupar los registros por estación de monitoreo, mientras que `agg()` aplicó múltiples funciones de agregación sobre distintas columnas del `DataFrame`.

La operación `mean` calculó el promedio de radiación gamma detectada por estación, mientras que `std` obtuvo la desviación estándar de las mediciones.

Asimismo, la operación `sum` permitió contabilizar la cantidad total de anomalías detectadas mediante la variable `is_outlier`.

Estas métricas facilitaron la construcción de visualizaciones comparativas entre estaciones y el análisis del comportamiento histórico de los sensores radiológicos.

9. Código y Análisis de Datos

El conjunto de operaciones lógicas fue programado mediante los módulos de la capa de ingeniería: `ingesta.py`, `perfilado.py`, `limpieza.py`, `fusion.py` y `analisis.py`.

A través del entorno integrado de `analisis.py`, se generaron 15 consultas estructuradas en visualizaciones enfocadas a 5 áreas de negocio:

1. **Impacto por Proximidad (Q01–Q03):** Histogramas, boxplots y regresiones lineales que comparan los conteos de gamma con la banda de distancia al reactor más cercano.
2. **Comportamiento de Anomalías (Q04–Q06):** Series temporales señalando valores atípicos y mapas de calor (*heatmaps*) anuales del Top 10 de estaciones más erráticas.

3. **Características de Infraestructura (Q07–Q09):** Gráficos de dispersión y correlación entre la capacidad energética en megavatios (MW) y las medias de radiación detectada según el tipo de reactor.
4. **Métricas Predictivas e Históricas (Q10–Q12):** Modelado gráfico apoyado en la antigüedad (años de recolección de datos) de las estaciones en función de sus registros actuales.
5. **Revisión de Calidad (Q13–Q15):** Identificación explícita y auditoría final de los sensores con problemas endémicos de reporte (nulos continuos).

9.1. P1 — Impacto por proximidad (Q01–Q03)

Las tres primeras consultas analizan si existe una relación entre la distancia de una estación a la planta nuclear más cercana y los niveles promedio de radiación gamma registrados.




Figura 1: Q01 – Distribución de `gamma_cpm` promedio por banda de distancia a planta nuclear (< 50 km, 50–200 km, > 200 km). Las estaciones más cercanas (< 50 km, rojo) concentran sus registros en rangos similares a las más lejanas, lo que sugiere que la proximidad por sí sola no eleva de forma clara los conteos en condiciones normales.




Figura 2: Q02 – Boxplot de `gamma_cpm` promedio por banda de distancia a planta operacional más cercana. Las medianas y rangos intercuartílicos son comparables entre las tres bandas, aunque la dispersión es ligeramente mayor en estaciones distantes (> 200 km), indicando mayor variabilidad en zonas alejadas de infraestructura nuclear.




Figura 3: Q03 – Regresión lineal entre la distancia a la planta más cercana (km) y el promedio de `gamma_cpm` por estación. La pendiente negativa ($r = -0,156$, $p = 0,0658$) sugiere una tendencia marginal a que las estaciones más cercanas registren conteos ligeramente más altos, aunque el resultado no alcanza significancia estadística convencional ($p > 0,05$).

9.2. P2 — Comportamiento de anomalías (Q04–Q06)

Este bloque caracteriza la distribución temporal y espacial de los valores atípicos catalogados con la bandera `is_outlier`.




Figura 4: Q04 – Serie temporal semanal de `gamma_cpm` para la estación `NV_LAS_VEGAS`, con puntos rojos indicando lecturas clasificadas como *outlier* por IQR. Se aprecia un pico pronunciado alrededor de 2008–2010 y una distribución de anomalías dispersa a lo largo de toda la serie histórica, consistente con fallos instrumentales puntuales.




Figura 5: Q05 – Top 10 estaciones con mayor tasa de anomalías (porcentaje de lecturas marcadas como *outlier*). `NH_PORTSMOUTH` lidera con un 17.1 %, seguida por `FL_TAMPA` (15.2 %) y `AZ_YUMA` (13.6 %). Estas estaciones son candidatas prioritarias para revisión de calibración de sensores.




Figura 6: Q06 – Mapa de calor de la frecuencia de *outliers* por estación y año (2006–2026). Los valores en celdas resaltadas indican picos aislados por año; estaciones como NY_NEW_YORK_CITY y ME_ORONO muestran episodios concentrados en años específicos, lo que apunta a eventos de mantenimiento o fallos de sensor puntuales.

9.3. P3 — Características de infraestructura (Q07–Q09)

Este bloque correlaciona los atributos físicos de las plantas nucleares (tipo de reactor, capacidad en MW) con los niveles de radiación gamma promedio detectados en las estaciones más cercanas.




Figura 7: Q07 – `gamma_cpm` promedio $\pm$ SEM por tipo de reactor más cercano (categorías IAEA). Los reactores PWR registran la media más alta (≈ 578 cpm), seguidos por PHWR (≈ 555 cpm) y BWR (≈ 518 cpm). Las diferencias entre tipos son modestas, lo que sugiere que el tipo de reactor no es el principal determinante de los niveles ambientales de radiación gamma.




Figura 8: Q08 – Diagrama de dispersión entre la capacidad instalada (MW) y el `gamma_cpm` promedio por estación, coloreado por tipo de reactor (PWR, BWR, PHWR). La correlación global es positiva pero débil ($r = 0,258$), indicando que plantas de mayor capacidad se asocian marginalmente a conteos gamma más altos en las estaciones cercanas.




Figura 9: Q09 – Matriz de correlación de Spearman entre las variables de infraestructura y calidad de datos. La correlación más alta se presenta entre `gamma_cpm_medio` y `gamma_cpm_std` ($r = 0,58$), lo que indica que las estaciones con mayor nivel promedio también presentan mayor variabilidad. La distancia y la capacidad muestran correlaciones débiles con los niveles de radiación.

9.4. P4 — Métricas predictivas e históricas (Q10–Q12)

Este bloque examina el comportamiento histórico de los sensores y la capacidad de modelos simples para predecir los niveles de radiación.




Figura 10: Q10 – Descomposición de serie temporal para la estación `AL_MONTGOMERY`: señal original (arriba), tendencia (centro) y residuo (abajo). La tendencia muestra un crecimiento inicial hasta 2010 y una posterior estabilización, mientras que el residuo revela episodios de alta variabilidad en los primeros años de operación del sensor.




Figura 11: Q11 – Predicción por media móvil de 12 meses versus valores reales para la estación CA_RIVERSIDE. La banda sombreada representa ± 1 desviación estándar. El modelo sigue razonablemente la tendencia general, aunque subestima los picos de alta variabilidad, lo que confirma la utilidad de este enfoque como línea base para detección de anomalías.




Figura 12: Q12 – Error absoluto medio (MAE) de la media móvil en función de la distancia a la planta nuclear más cercana ($r = -0,153$, $p = 0,0715$). Las estaciones más cercanas a una planta tienden a presentar un error de predicción ligeramente mayor, lo que podría indicar una mayor irregularidad en sus series temporales asociada a la proximidad a infraestructura nuclear.

9.5. P5 — Revisión de calidad (Q13–Q15)

El bloque final constituye una auditoría formal de la calidad residual de los datos tras el pipeline, identificando los sensores con mayores problemas endémicos de reporte.




Figura 13: Q13 – Ranking de las 20 estaciones con peor índice compuesto de calidad de datos (0 = mejor, 1 = peor). La estación KS_DODGE_CITY presenta el índice más alto (0.392), superando la media global (0.309, línea punteada). Estas estaciones son candidatas prioritarias para intervención de mantenimiento o reemplazo de sensores.




Figura 14: Q14 – Porcentaje de registros con `dose_nSv_h` nulo por estación, ordenadas de mayor a menor. La línea punteada indica el promedio global del 69.9%. La mayoría de las estaciones superan este umbral, con algunas alcanzando casi el 100% de nulos, lo que confirma la necesidad de la imputación implementada en el pipeline de limpieza.




Figura 15: Q15 – Proporción de registros reales versus imputados (mediana/estación) para las 20 estaciones con mayor tasa de imputación. La estación NY_ROCHESTER encabeza la lista con la mayor proporción de valores imputados (rojo) respecto a mediciones reales (azul), evidenciando la dependencia de estas estaciones en la estrategia de imputación implementada.

10. Conclusiones

10.1. En términos de la realización del proyecto de calidad de datos

El uso metodológico de un framework de calidad demostró ser fundamental para homogeneizar dos fuentes de origen completamente distinto. Herramientas técnicas como la geocodificación mediante API recuperaron cientos de registros sin los cuales el estudio de proximidad habría carecido de validez

espacial. Adicionalmente, se probó el valor de las métricas descriptivas y de linaje de datos, pues el uso de flags como `gamma_imputed` o `is_outlier` garantizan la transparencia en análisis estadísticos futuros.

10.2. En términos de dominio de negocio y resultado del análisis

El análisis a través de nuestro dato maestro consolidado brinda herramientas empíricas y visuales para determinar si la proximidad a centrales nucleares operacionales efectivamente altera los registros radiológicos ambientales en los sensores de la EPA, o si, por el contrario, los picos anómalos son producto de fallas de calibración del sensor. Al cruzar datos de infraestructura global y reportes radiológicos a este nivel de completitud y limpieza, se sientan las bases analíticas precisas para políticas de salud pública eficientes e informadas en evidencia estadística de alta confiabilidad.